Decidir con *datos*:

de los hornos al código

Pruebas de bondad de ajuste (χ^2, Kolmogorov–Smirnov y Anderson–Darling), intervalos de confianza y pruebas de hipótesis aplicados a un estudio de mercado de hornos a gas, a la comparación de dos equipos de procesamiento y a dos casos con datos **reales** de Ingeniería de Sistemas e Ingeniería Industrial, con una herramienta propia en Python.

INTEGRANTES

Juan Manuel Moreno Muñoz · David Restrepo · Juan Fernando

PROFESOR

Horacio Fernández C.

Medellín, octubre de 2026

Resumen

Este proyecto aplica las herramientas de la Estadística para Ingeniería a la toma de decisiones en tres problemas. En el **primero**, con una base de 3 665 hornos de cinco marcas, se comparan las emisiones y la potencia, se elige la marca de mejor desempeño (Marca 2) y se construyen intervalos de confianza para su media, su varianza y su proporción de cumplimiento; además se contrastan la variabilidad de dos tecnologías y la afirmación de un fabricante. En el **segundo**, con datos simulados, se comparan dos equipos de procesamiento mediante pruebas de bondad de ajuste, pruebas t y Z y la prueba no paramétrica de Mann–Whitney, y se mide la potencia de cada prueba con un estudio de Monte Carlo. En el **tercero** se analizan datos reales: el historial de 2 238 commits del proyecto de código abierto Streamlit (Ingeniería de Sistemas) y dos bases clásicas de control de calidad (Ingeniería Industrial). Como valor agregado se explican y aplican las pruebas de Kolmogorov–Smirnov y Anderson–Darling, con valores p corregidos por simulación cuando los parámetros se estiman, y se entrega una aplicación web que permite repetir todo el análisis con cualquier archivo de datos.

Palabras clave: bondad de ajuste, Kolmogorov–Smirnov, Anderson–Darling, Mann–Whitney, intervalos de confianza, control estadístico de procesos, binomial negativa.

Contenido

Introducción 1

1 Marco teórico 2

1.1 Estimación e intervalos de confianza . . . 2

1.2 Pruebas de hipótesis . . . 2

1.3 Pruebas de bondad de ajuste . . . 2

1.3.1 El problema de estimar los parámetros: Lilliefors y el bootstrap paramétrico . . . 4

1.4 Prueba de Mann–Whitney (Wilcoxon de suma de rangos) . . . 4

1.5 Control estadístico de procesos . . . 5

2 Punto 1: estudio de mercado de hornos a gas 5

3 Punto 2: comparación de dos equipos de procesamiento 9

4 Punto 3: la Estadística en nuestras carreras, con datos reales 12

4.1 Ingeniería de Sistemas: el flujo de cambios de un proyecto de software . . . 13

4.2 Ingeniería Industrial: ¿el proceso es capaz y está bajo control? . . . 15

Conclusiones 16

Referencias 17

A La herramienta en Python 18

B Taller de la guía resuelto 19

C Reproducibilidad: Python, Excel y R 20

Introducción

En ingeniería casi ninguna decisión se toma con certeza: el horno que se compra, el servidor que se dimensiona o la máquina que se ajusta se eligen a partir de muestras, y las muestras varían. La Estadística ofrece el lenguaje para cuantificar esa incertidumbre y decidir con un riesgo conocido. Este informe reúne los temas del curso —estadística descriptiva, distribuciones de probabilidad, estimación, intervalos de confianza, pruebas de hipótesis y bondad de ajuste— y los aplica a tres problemas, siguiendo el enunciado del proyecto de aula.

Un hilo conductor atraviesa todo el trabajo: *casi todos los métodos inferenciales suponen un modelo* (que los datos sean normales, que los conteos sean Poisson o binomiales). Por eso las pruebas de bondad de ajuste no son un tema aislado: son el paso que valida los demás. La guía del curso presenta la prueba χ^2 [1]; como valor agregado se estudian a fondo las pruebas de Kolmogorov–Smirnov (KS) y Anderson–Darling (AD), que no necesitan agrupar los datos y son más potentes [9, 11].

El documento se organiza así: la sección 1 presenta el marco teórico; las secciones 2, 3 y 4 desarrollan los tres puntos del enunciado; al final se presentan las conclusiones y, en los anexos, la herramienta construida, la solución del taller de la guía y la equivalencia de los cálculos en Excel y R. Para garantizar la reproducibilidad, todos los números del informe se generan con el código del repositorio (semilla 2026) y ninguno se copió a mano.

> HERRAMIENTA La aplicación web (Python + Streamlit) incluye cada punto con sus gráficas interactivas, un laboratorio para subir *cualquier* archivo (CSV, Excel, TXT, JSON) y aplicarle todas las pruebas, la teoría de las tres pruebas de ajuste con simulaciones y la guía de bondad de ajuste resuelta. Véase el anexo A.

1 Marco teórico

1.1 Estimación e intervalos de confianza

Un estimador es una función de la muestra que aproxima un parámetro. En el proyecto se usan los estimadores de **máxima verosimilitud** (MV): $\hat{\theta} = \arg\max_\theta \prod_{i=1}^{n} f(x_i;\theta)$. Para la Poisson $\hat{\lambda} = \bar{x}$; para la binomial $\hat{p} = \bar{x}/n$; para la gamma (forma α, escala β) y la lognormal las ecuaciones se resuelven numéricamente. Los intervalos utilizados son [2, 3]:

$$\bar{x} \pm t_{\alpha/2,\,n-1}\frac{s}{\sqrt{n}}, \qquad \frac{(n-1)s^2}{\chi^2_{\alpha/2,\,n-1}} \le \sigma^2 \le \frac{(n-1)s^2}{\chi^2_{1-\alpha/2,\,n-1}}, \qquad \hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \tag{1}$$

donde $\chi^2_{a,v}$ deja un área a a su derecha. El de la media es válido para n grande aunque los datos no sean normales (Teorema del Límite Central); el de la varianza *exige normalidad*, y por eso se verifica antes con pruebas de ajuste.

1.2 Pruebas de hipótesis

Se plantea H_0 y se calcula un estadístico cuya distribución es conocida cuando H_0 es cierta; se rechaza H_0 si el valor P es menor que el nivel de significancia α (aquí 0.05). La tabla 1 resume los estadísticos del proyecto.

Tabla 1. Estadísticos de prueba utilizados.

Hipótesis nula	**Estadístico**	**Distribución bajo H_0**
$\sigma_1^2 = \sigma_2^2$	$F = s_1^2/s_2^2$	$F_{(n_1-1,\,n_2-1)}$
$\mu_1 = \mu_2$ (σ^2 iguales)	$t = \dfrac{\bar{x}_1 - \bar{x}_2}{s_p\sqrt{1/n_1 + 1/n_2}}$	$t_{(n_1+n_2-2)}$
$\mu_1 = \mu_2$ (σ^2 distintas, Welch)	$t = \dfrac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	$t_{(v)}$, v de Satterthwaite
$\mu_1 = \mu_2$ (n grande)	$Z = \dfrac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	$N(0,1)$ por el TLC
$p = p_0$	$Z = \dfrac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	$N(0,1)$

1.3 Pruebas de bondad de ajuste

Contrastan H_0: *la muestra proviene de la distribución* F_0 contra H_a: *no proviene de* F_0 [1]. Las tres pruebas del proyecto miden la discrepancia entre los datos y F_0 de forma distinta.

Definición 1.1: Prueba χ^2 de Pearson

Se agrupan los n datos en k clases con frecuencias observadas O_i. Si P_i es la probabilidad de la clase i bajo F_0 y $E_i = nP_i$, el estadístico

$$EP = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{(v)}, \qquad v = k - p - 1,$$

donde p es el número de parámetros estimados con la muestra. Se rechaza H_0 si $EP > \chi^2_{(\alpha,v)}$. Se exige $E_i \geq 5$, agrupando clases adyacentes si es necesario, y k es el menor entero con $2^k > n$.

Es la única de las tres que sirve para variables *discretas*. Su debilidad es que al agrupar pierde información y que el resultado depende de las clases. Con datos muy asimétricos, las clases de igual ancho dejan casi todo en la primera clase y, tras agrupar, quedan pocos grados de libertad; por eso también se usa la variante con **clases equiprobables** ($P_i = 1/k$ para todas, de modo que $E_i = n/k$).

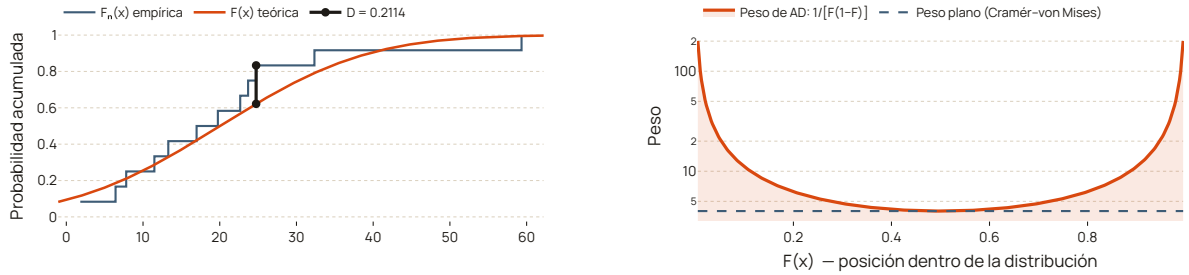
Definición 1.2: Función de distribución empírica y estadístico de Kolmogorov–Smirnov

Con la muestra ordenada $x_{(1)} \leq \cdots \leq x_{(n)}$, la función empírica es $F_n(x) = \#\{x_i \leq x\}/n$, una escalera que sube $1/n$ en cada dato. El estadístico KS es la mayor distancia vertical entre F_n y F_0 [5, 6]:

$$D = \sup_x |F_n(x) - F_0(x)| = \max(D^+, D^-), \quad D^+ = \max_i \left(\tfrac{i}{n} - F_0(x_{(i)})\right), \quad D^- = \max_i \left(F_0(x_{(i)}) - \tfrac{i-1}{n}\right).$$

Teorema 1.1: Glivenko–Cantelli y distribución de Kolmogorov

Si H_0 es cierta, $D \to 0$ con probabilidad 1 cuando $n \to \infty$. Si además F_0 es continua y está completamente especificada, la distribución de D no depende de F_0 y $P(\sqrt{n}\,D > t) \to 2\sum_{j\geq 1}(-1)^{j-1}e^{-2j^2t^2}$; al 5 % el valor crítico es aproximadamente $1.36/\sqrt{n}$.



(a) KS: la mayor distancia vertical D. **(b)** AD: peso $1/[F(1-F)]$ en escala logarítmica.

Figura 1. Cómo miden la discrepancia las pruebas KS y AD.

Definición 1.3: Estadístico de Anderson–Darling

Anderson y Darling [7, 8] proponen sumar las diferencias al cuadrado en todo el rango, ponderadas por

$\psi(F) = 1/[F(1-F)]$:

$$A^2 = n\int_{-\infty}^{\infty} \frac{[F_n(x)-F_0(x)]^2}{F_0(x)[1-F_0(x)]}\,dF_0(x) = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\Big[\ln F_0(x_{(i)}) + \ln\big(1-F_0(x_{(n+1-i)})\big)\Big].$$

El peso vale 4 en la mediana y crece sin límite cuando $F \to 0$ o $F \to 1$ (figura 1b): una misma diferencia pesa mucho más en las **colas**. En ingeniería las colas son justamente lo importante (el horno que más contamina, el tiempo de respuesta más lento), y por eso AD es la más potente de las tres. Sus valores críticos dependen de F_0: para la normal con μ y σ estimadas, Stephens [9] usa $A^* = A^2(1 + 0.75/n + 2.25/n^2)$ con crítico 0.752 al 5 %; con parámetros conocidos el crítico es 2.492.

1.3.1 El problema de estimar los parámetros: Lilliefors y el bootstrap paramétrico

El teorema 1.1 supone F_0 *conocida*. Si sus parámetros se estiman con la misma muestra, el modelo "se acomoda" a los datos y D sale más pequeño, así que la tabla de Kolmogorov ya no sirve [10]. Se verificó por simulación: con 2000 muestras normales de tamaño 60, la prueba con la tabla rechazó el 4.7 % de las veces cuando μ, σ eran conocidas (correcto, $\approx \alpha$), pero solo el 0.0 % cuando se estimaban; el crítico real es 0.1130 y no 0.1723. Por eso, en todo el proyecto los valores P de KS y AD se obtienen por Monte Carlo:

Valor P por bootstrap paramétrico (corrección de Lilliefors generalizada)

1. Estimar $\hat\theta$ con la muestra y calcular el estadístico observado (D o A^2).
2. Repetir $B = 999$ veces: simular n datos de $F_0(\cdot;\hat\theta)$, *re-estimar* $\hat\theta^*$ con ellos y calcular el estadístico D^* o A^{2*}.
3. Valor $P \approx (\#\{\text{estadísticos simulados} \geq \text{observado}\} + 1)/(B+1)$.

La tabla 2 compara, también por simulación, la **potencia** de las tres pruebas para detectar que unos datos *no* son normales ($n = 60$): AD es la mejor en los tres casos y χ^2 la peor, en línea con lo reportado por Razali y Wah [11].

Tabla 2. Porcentaje de veces que cada prueba rechaza la normalidad (600 réplicas, $n = 60$, $\alpha = 0.05$).

Datos generados desde	χ^2 (equiprobables)	Kolmogorov–Smirnov	Anderson–Darling
t de Student (4 gl): colas pesadas	28.5 %	33.2 %	47.2 %
Gamma($\alpha = 4$): asimétrica	23.3 %	44.5 %	66.8 %
Uniforme: sin colas	27.0 %	32.7 %	69.2 %

1.4 Prueba de Mann–Whitney (Wilcoxon de suma de rangos)

Es la alternativa no paramétrica a la prueba t para dos muestras independientes [12, 13].

Definición 1.4: Estadístico U de Mann–Whitney

Se juntan las $N = n_1 + n_2$ observaciones, se ordenan y se asigna a cada una su rango (los empates reciben el rango promedio). Si R_1 es la suma de rangos de la muestra 1, $U_1 = R_1 - n_1(n_1+1)/2$ es el número de pares (x_{1i}, x_{2j}) con $x_{1i} > x_{2j}$. H_0: ambas poblaciones son iguales, es decir, $P(X_1 > X_2) = 0.5$.

Teorema 1.2: Normalidad asintótica de U

Bajo H_0, $E[U] = \frac{n_1 n_2}{2}$ *y* $Var[U] = \frac{n_1 n_2}{12}\left[(N+1) - \frac{\sum_j (t_j^3 - t_j)}{N(N-1)}\right]$ (t_j: *tamaño de cada grupo de empates*); *para* $n_1, n_2 > 10$, $Z = (U_1 - E[U])/\sqrt{Var[U]} \approx N(0,1)$.

Como solo usa el orden, no exige normalidad y no la afectan los atípicos; si los datos sí son normales pierde poca potencia frente a la t (eficiencia asintótica $3/\pi \approx 0.955$).

1.5 Control estadístico de procesos

Con especificaciones $[LIE, LSE]$, los índices de capacidad son $C_p = (LSE - LIE)/6s$ y $C_{pk} = \min(LSE - \bar{x},\ \bar{x} - LIE)/3s$; un proceso se considera capaz si $C_{pk} \geq 1.33$ [4]. Las cartas de control $\bar{X}$–R usan los límites $\bar{\bar{x}} \pm A_2\bar{R}$ y $[D_3\bar{R}, D_4\bar{R}]$ (para muestras de 5: $A_2 = 0.577$, $D_3 = 0$, $D_4 = 2.114$), y la carta p, $\bar{p} \pm 3\sqrt{\bar{p}(1-\bar{p})/n}$; ambas suponen normalidad o binomialidad, que se verifican con las pruebas de ajuste.

2 Punto 1: estudio de mercado de hornos a gas

La base contiene 3 665 hornos de cinco marcas con su tiempo de uso, número de reparaciones, emisiones (ppm) y potencia (kW). Los datos son **inventados** pero coherentes con el enunciado: las emisiones crecen con el uso y con las reparaciones, las reparaciones son conteos de Poisson y la potencia se degrada levemente con los años. Especificaciones: potencia 2.7 ± 0.22 kW ($LIE = 2.48$, $LSE = 2.92$) y emisiones de máximo 400 ppm por seguridad (la norma permite 1000).

a) Emisiones: diagrama de cajas y bigotes

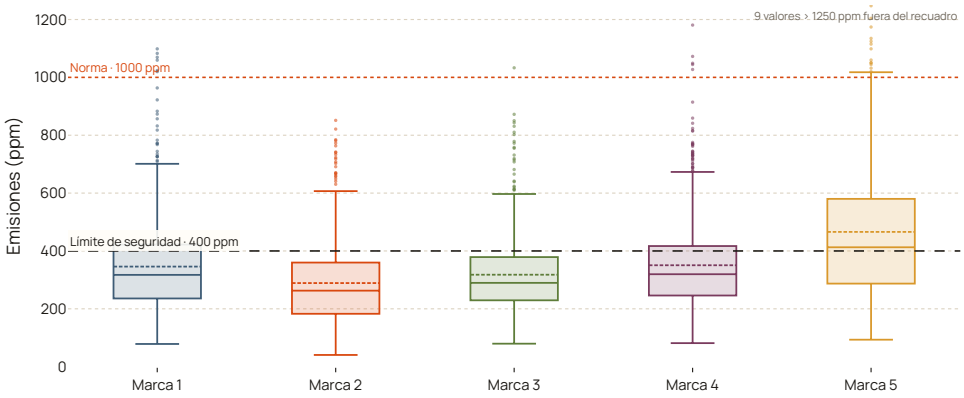


Figura 2. Emisiones por marca. La línea discontinua es el límite de seguridad; la punteada roja, la norma.

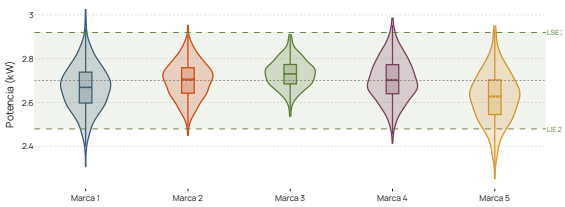
Tabla 3. Resumen de las emisiones (ppm) por marca.

Marca	n	Media	Mediana	Q1	Q3	RIC	Atípicos	% $\leq$ 400 ppm	% > 1000 ppm
Marca 1	812	346.0	317.4	235.9	422.2	186.2	24	71.3	0.74
Marca 2	694	289.0	262.8	182.9	359.9	177.0	22	81.3	0.00
Marca 3	735	317.9	289.7	229.4	378.8	149.3	24	78.8	0.14
Marca 4	768	350.6	319.6	246.0	416.9	170.9	38	71.1	0.65
Marca 5	656	465.9	412.8	287.2	579.8	292.5	22	47.9	3.66

LECTURA

Las cinco cajas son asimétricas a la derecha: bigote superior largo y atípicos solo hacia arriba, porque unos pocos hornos (los más usados o reparados) emiten mucho más que el resto. **Marca 2 es la que menos contamina**: tiene la caja más baja, la menor mediana (262.8 ppm), el 81.3 % de sus hornos bajo 400 ppm y ninguno sobre la norma. Marca 5 es la peor (mediana 412.8 ppm, 3.66 % sobre 1000 ppm). La diferencia no es casual: Kruskal–Wallis da $H = 298.8$ ($P < 0.0001$) y Mann–Whitney entre las dos mejores, Marca 2 y Marca 3, da $Z = -5.393$ ($P < 0.0001$).

b) Cumplimiento de la especificación de potencia



Marca	n	Media	Desv. (s)	$\lvert\bar{x} - 2.70\rvert$	% dentro de espec.
Marca 1	812	2.6685	0.1036	0.0315	94.83
Marca 2	694	2.7021	0.0829	0.0021	99.71
Marca 3	735	2.7314	0.0640	0.0314	100.00
Marca 4	768	2.7051	0.0968	0.0051	98.05
Marca 5	656	2.6250	0.1142	0.0750	89.02

Figura 3. Potencia por marca (franja verde: especificación) e índices de capacidad.

LECTURA

La media cercana a 2.70 kW no basta; importa cuántas desviaciones caben hasta el límite más cercano, que es lo que mide C_{pk}. **Marca 3 es la que mejor se ajusta** a la especificación: el mayor C_{pk} (0.982), la menor desviación (0.0640 kW) y el 100.00 % de sus hornos dentro de 2.48–2.92 kW. Marca 2 está mejor centrada ($\bar{x} = 2.7021$) pero es más dispersa ($C_{pk} = 0.876$). Ninguna marca alcanza $C_{pk} \geq 1.33$, y Marca 5 es la peor ($C_{pk} = 0.423$, 89.02 % en especificación).

c) Marca de mejor desempeño

Se ordenaron las marcas (1 = mejor) en cinco criterios con igual peso; las reparaciones se dividen entre los años de uso para no castigar a las marcas con hornos más antiguos.

Tabla 4. Criterios de desempeño y puesto de cada marca.

Marca	Mediana ppm	% ≤ 400 ppm	Cpk potencia	% pot. en espec.	Rep./año	Suma	Puesto
Marca 2	262.8	81.3	0.876	99.71	0.0683	7	1
Marca 3	289.7	78.8	0.982	100.00	0.0961	8	2
Marca 4	319.6	71.1	0.740	98.05	0.1088	17	3
Marca 1	317.4	71.3	0.606	94.83	0.1319	18	4
Marca 5	412.8	47.9	0.423	89.02	0.2049	25	5

LECTURA

Marca 2 tiene el mejor desempeño (suma 7): es la que menos contamina, la que menos se daña (0.068 reparaciones por año de uso, frente a 0.205 de Marca 5) y la segunda en potencia. Marca 3 queda cerca (suma 8) gracias a su potencia más estable. Si la prioridad fuera solo la estabilidad del quemador se elegiría Marca 3; como el enunciado prioriza seguridad y desempeño global, se escoge Marca 2.

d) Intervalos de confianza del 95 % para Marca 2

Antes de construir el intervalo de la varianza se verificó la normalidad de la potencia: χ^2: $EP = 9.314$, $v = 7$, $P = 0.231$; KS: $D = 0.0292$, $P = 0.168$; AD: $A^2 = 0.653$, $P = 0.091$. Ninguna prueba rechaza, así que la ecuación (1) es aplicable ($n = 694$):

$$\mu:\ 2.7021 \pm 1.9634 \cdot \frac{0.0829}{\sqrt{694}} = 2.7021 \pm 0.0062 \quad \Rightarrow \quad \boxed{2.6959 \leq \mu \leq 2.7083 \text{ kW}}$$

$$\sigma^2:\ \frac{(694-1)\,0.006874}{767.84} \leq \sigma^2 \leq \frac{(694-1)\,0.006874}{621.94} \quad \Rightarrow \quad \boxed{0.006204 \leq \sigma^2 \leq 0.007659 \text{ kW}^2}$$

$$p:\ 0.8127 \pm 1.96\sqrt{\frac{0.8127(1-0.8127)}{694}} = 0.8127 \pm 0.0290 \quad \Rightarrow \quad \boxed{0.7837 \leq p \leq 0.8417}$$

LECTURA

Con 95 % de confianza, la potencia media de Marca 2 está entre 2.6959 y 2.7083 kW, intervalo que **contiene el valor nominal 2.70**: el proceso está centrado. La desviación estándar está entre 0.0788 y 0.0875 kW, y entre el 0.7837 y el 0.8417 de los hornos (564 de 694 en la muestra) cumple el límite de 400 ppm (intervalo de Wilson: 0.7820–0.8400).

e) Variabilidad de la potencia: Marca 3 frente a Marca 4

$H_0 : \sigma_3^2 = \sigma_4^2$ contra $H_a : \sigma_3^2 \neq \sigma_4^2$. La prueba F supone normalidad, que se verificó para ambas marcas (AD: $P = 0.843$ y $P = 0.230$).

$$F = \frac{s_4^2}{s_3^2} = \frac{0.009362}{0.004101} = 2.2829 \qquad F_{(0.025;767,734)} = 1.1541 \qquad P < 0.0001$$

$$\text{IC 95 \% de } \sigma_4^2/\sigma_3^2 : \ [1.978,\ 2.634]$$

LECTURA

SE RECHAZA H_0 La desviación de Marca 4 (0.0968 kW) es 1.51 veces la de Marca 3 (0.0640 kW); el intervalo para la razón de varianzas no contiene el 1 y la prueba de Levene, que no exige normalidad, lo confirma ($W = 111.19$, $P < 0.0001$). **Sí hay diferencia: la tecnología de Marca 3 produce una potencia más uniforme.**

f) ¿80 de cada 100 hornos de Marca 2 cumplen la norma de emisión?

$H_0 : p = 0.80$ contra $H_a : p \neq 0.80$: $Z = (0.8127 - 0.80)/\sqrt{0.80(0.20)/694} = 0.8351$, con crítico ± 1.9600 y $P = 0.4037$. Para la versión unilateral $H_a : p < 0.80$, $P = 0.7982$.

LECTURA

NO SE RECHAZA H_0 La proporción observada (0.8127) está a solo 0.8351 errores estándar del 80 %, y el intervalo del literal d) contiene 0.80. **Estamos de acuerdo con la afirmación del fabricante**: los datos son consistentes con que 80 de cada 100 hornos cumplen.

Relaciones entre las variables

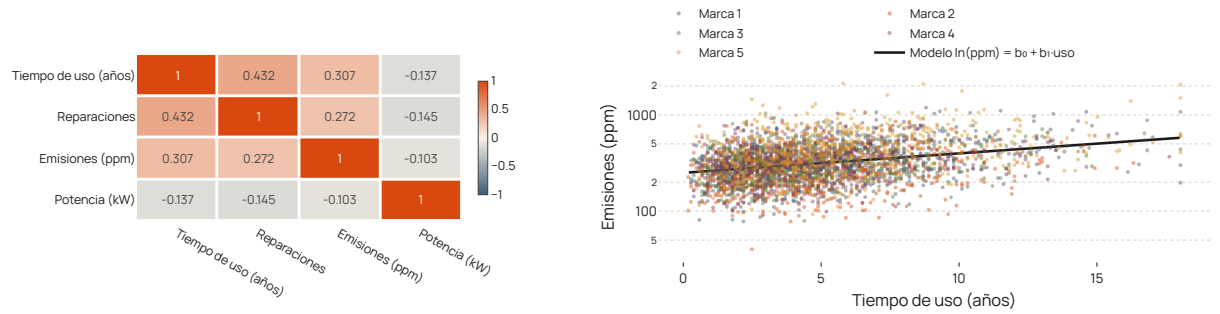


Figura 4. Correlaciones de Pearson y modelo log-lineal de las emisiones frente al tiempo de uso.

Las emisiones aumentan con el tiempo de uso ($r = 0.307$) y con las reparaciones ($r = 0.272$), y la potencia baja levemente con los años ($r = -0.137$). El modelo $\ln(\widehat{ppm}) = 5.5219 + 0.0466 \cdot \text{uso}$ indica que **cada año de uso aumenta las emisiones un 4.77 %** en promedio. Las reparaciones de Marca 2 se ajustan a una Poisson con $\hat{\lambda} = 0.3141$ ($EP = 0.0814$, $v = 1$, $P = 0.7755$).

3 Punto 2: comparación de dos equipos de procesamiento

Se generaron 60 tiempos (ms) por equipo con semilla 2026: en el escenario 1, $A \sim N(175, 30)$ y $B \sim N(170, 50)$; en el escenario 2, $A \sim \Gamma(\alpha = 1.2, \beta = 150)$ y $B \sim \Gamma(0.95, 190)$, con β como parámetro de escala ($E[X] = \alpha\beta$: 180 y 180.5 ms).

a) Histogramas, medidas descriptivas y pruebas de bondad de ajuste

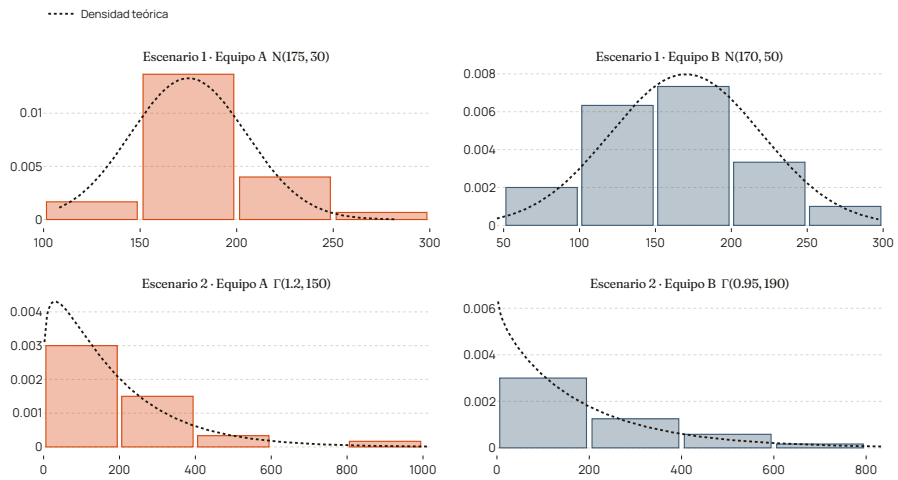


Figura 5. Histogramas ($k = 6$ clases, $2^6 > 60$) con la densidad de la que se simularon los datos.

Tabla 5. Medidas descriptivas de los cuatro grupos (ms).

Medida	E1 · A	E1 · B	E2 · A	E2 · B
Media	181.95	163.37	201.52	197.97
Mediana	180.04	165.26	167.64	134.59
Desv. estándar (s)	29.42	51.89	187.04	173.29
Coef. de variación (%)	16.17	31.76	92.81	87.53
Mínimo	118.11	55.60	2.58	2.52
Q1	161.13	123.66	69.53	79.75
Q3	197.40	194.74	268.49	282.13
Máximo	269.53	282.73	969.43	796.96
Asimetría	0.58	0.15	2.18	1.26
Curtosis (exceso)	0.53	-0.45	6.50	1.50

Las medias muestrales del escenario 1 (181.95 y 163.37) se alejan de las teóricas más de lo que podría parecer, lo que anticipa el literal b. En el escenario 2 la desviación es casi igual a la media (en la gamma, $CV = 1/\sqrt{\alpha}$) y la asimetría es fuerte (2.18 y 1.26).

Ejemplo detallado (E1·A contra la normal). Con $\hat{\mu} = 181.946$ y $\hat{\sigma} = 29.415$ ($p = 2$), las 6 clases de igual ancho se reducen a 5 al exigir $E_i \geq 5$ (tabla 6): $EP = 4.9110$, $v = 5 - 2 - 1 = 2$, $\chi^2_{(0.05,2)} =$

5.9915, $P = 0.0858$. KS: $D = 0.0852$, $P = 0.358$ (Lilliefors; el valor P clásico 0.744 es demasiado optimista). AD: $A^2 = 0.4573$, $A^* = 0.4633 < 0.752$, $P = 0.232$. Las tres pruebas concluyen que **no se rechaza la normalidad**.

Tabla 6. Prueba χ^2 para E1·A contra $N(181.946,\ 29.415)$.

Clase	O_i	P_i	$E_i = nP_i$	$(O_i - E_i)^2/E_i$
x ≤ 143.3	4	0.09472	5.683	0.4986
(143.3, 168.6]	20	0.23009	13.806	2.7794
(168.6, 193.8]	15	0.33196	19.917	1.2141
(193.8, 219.1]	16	0.23968	14.381	0.1822
x > 219.1	5	0.10354	6.213	0.2367

Tabla 7. Valores P de las pruebas de ajuste a la normal y a la gamma (en rojo, $P < 0.05$).

Grupo	Modelo	χ^2 guía	v guía	χ^2 equiprob.	KS	AD
E1 · A	Normal	0.0858	2	0.2035	0.3580	0.2320
E1 · A	Gamma	0.0856	1	0.2615	0.6700	0.7380
E1 · B	Normal	0.7260	2	0.0937	0.3710	0.8750
E1 · B	Gamma	0.4538	1	0.7055	0.4730	0.6180
E2 · A	Normal	v<1	0	**0.0017**	**0.0050**	**0.0010**
E2 · A	Gamma	v<1	0	0.4936	0.7700	0.6000
E2 · B	Normal	**0.0078**	1	**0.0321**	**0.0010**	**0.0010**
E2 · B	Gamma	0.2484	1	0.1328	0.7920	0.8170

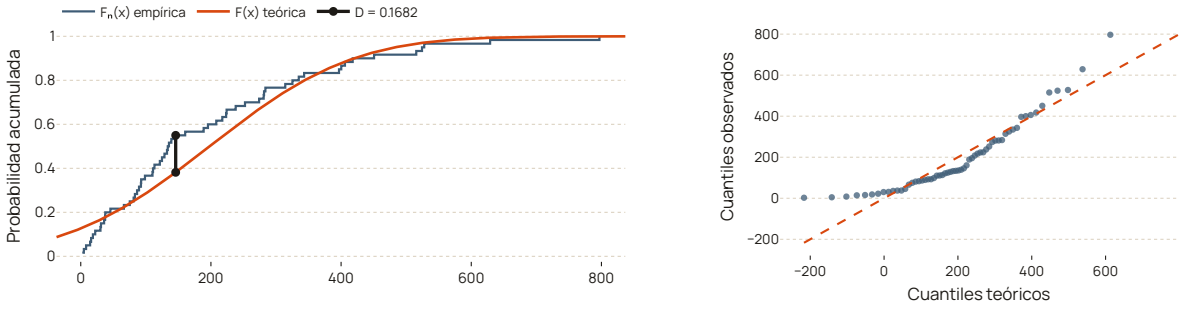


Figura 6. E2·B contra la normal: escalera empírica, curva normal ajustada y gráfico Q-Q.

LECTURA

En el **escenario 1** ninguna prueba rechaza la normal, como se esperaba; tampoco se rechaza la gamma, porque con α grande la gamma se parece a la normal y 60 datos no alcanzan para distinguirlas. En el **escenario 2** KS ($D = 0.1682$, P0.0010 para E2·B) y AD ($A^2 = 1.990$, P0.0010) rechazan la normal, mientras que la gamma se acepta (E2·B: $\hat{\alpha} = 1.115$, $\hat{\beta} = 177.51$, AD $P = 0.817$). La χ^2 con clases de igual ancho *no puede decidir* en E2·A: la cola larga deja casi todos los datos en la primera clase y, al agrupar, $v < 1$. Ese es el argumento central para usar KS y AD: no agrupan y aprovechan cada dato. En el gráfico Q-Q la curvatura en el extremo superior muestra la cola que la normal no puede reproducir.

b) Comparación de medias con t-Student y con la normal

Para cada escenario se probó primero la igualdad de varianzas con F (E1: $F = 3.112$, $P < 0.0001$, distintas → t de Welch; E2: $F = 1.165$, $P = 0.5595$ → t combinada). Luego, $H_0 : \mu_A = \mu_B$:

Tabla 8. Pruebas de comparación entre los equipos A y B.

Escenario	$\bar{x}_A - \bar{x}_B$	p (F)	t	gl	p (t)	Z	p (Z)	U_A	Z_{MW}	p (MW)
1 (normales)	18.5780	0.0000	2.4125	93.37	0.0178	2.4125	0.0158	2 228	2.2464	0.0247
2 (gamma)	3.5542	0.5595	0.1080	118.00	0.9142	0.1080	0.9140	1 828	0.1443	0.8852

LECTURA

El estadístico es el **mismo número** con las dos distribuciones (E1: $t = Z = 2.4125$), porque ambas dividen la diferencia de medias entre el mismo error estándar; cambia la distribución de referencia. La t tiene colas más pesadas y siempre da un valor P algo mayor (E1: 0.0178 frente a 0.0158): es la más *conservadora*. Con 60 datos por grupo la diferencia es pequeña porque $t_{(93.37)}$ ya es casi normal, y por el TLC la Z es válida aunque los datos no sean normales. En el escenario 1 **se rechaza** H_0 (diferencia observada 18.578 ms); en el escenario 2 **no se rechaza** ($P = 0.9142$), coherente con medias teóricas casi iguales.

c) Prueba de Mann–Whitney

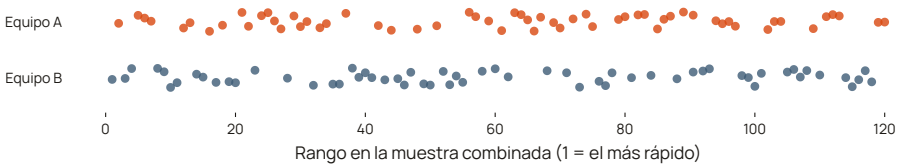


Figura 7. Rangos de los 120 tiempos del escenario 2 en la muestra combinada (1 = el más rápido).

Escenario 2: $R_A = 3\,657.5$, $U_A = 3\,657.5 - \frac{60 \cdot 61}{2} = 1\,827.5$, $E[U] = 1\,800$, $\sigma_U = 190.525$, $Z = 0.1443$, $P = 0.8852$ (exacto: 0.8873). Escenario 1: $U_A = 2\,228.0$, $Z = 2.2464$, $P = 0.0247$.

LECTURA

En el **escenario 1**, con datos normales, Mann–Whitney y la t llegan a la misma decisión ($P = 0.0247$ y 0.0178): se rechaza H_0. En el **escenario 2** ninguna rechaza ($P = 0.8852$ y 0.9142), pero aquí Mann–Whitney es la prueba apropiada, porque los datos no son normales (literal a) y la media está dominada por unos pocos tiempos muy largos. Su lectura es directa: tomado un trabajo al azar de cada equipo, el de A tarda más en el $0.508 \times 100\,\%$ de los pares, prácticamente la mitad.

Valor agregado: ¿qué prueba es mejor? Un estudio de Monte Carlo

Una sola muestra puede engañar. Se repitió 4000 veces el experimento completo y se contó cuántas veces cada prueba rechaza H_0 (figura 8).

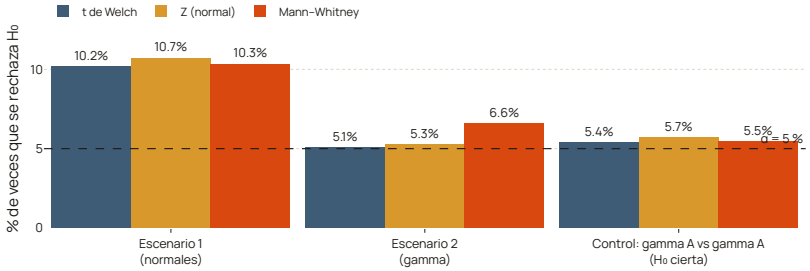


Figura 8. Porcentaje de rechazos en 4000 experimentos simulados por escenario.

LECTURA

Con dos poblaciones iguales (control) las tres pruebas rechazan cerca del 5 % (5.4, 5.7 y 5.5 %): están bien calibradas incluso con datos gamma. En el **escenario 1** la potencia apenas llega al 10.2 %: con desviaciones de 30 y 50 ms, una diferencia real de 5 ms casi nunca se detecta con 60 datos, así que **la muestra de este informe fue "afortunada"**. En el **escenario 2**, t y Z rechazan $\approx$5 %, porque las medias son iguales, mientras que Mann–Whitney rechaza algo más (6.6 %) porque detecta la diferencia de *forma*: $P(A > B) = 0.522 \neq 0.5$.

4 Punto 3: la Estadística en nuestras carreras, con datos reales

En **Ingeniería de Sistemas** la Estadística sostiene el aprendizaje automático (modelos, validación, intervalos para métricas), las pruebas A/B de producto, la teoría de colas y la planeación de capacidad de servidores, la confiabilidad y la detección de anomalías en seguridad, y las métricas de entrega de software (DevOps), cuyo estudio más conocido es el de Forsgren, Humble y Kim [14]. En **Ingeniería Industrial** es la base del control estadístico de procesos, el análisis de capacidad, Seis Sigma, el diseño de experimentos, el muestreo de aceptación, el pronóstico de demanda y la simulación de sistemas productivos [4]. Como el grupo reúne estudiantes de ambas carreras, se desarrolló una aplicación de cada una.

4.1 Ingeniería de Sistemas: el flujo de cambios de un proyecto de software

a) Problema. Para dimensionar la integración continua (CI) y la capacidad de revisión de código, un equipo necesita saber cuántos cambios llegan por día, de qué tamaño y si sirve el modelo de Poisson de la teoría de colas. Se requieren la fecha, el tipo y el tamaño de cada cambio integrado, que se obtienen del historial de Git.

b) Datos. Se extrajo con `git log --first-parent --numstat` el historial de la rama principal de Streamlit [15] entre el 1 de enero de 2024 y el 31 de diciembre de 2025. Tras quitar bots, publicaciones de versión y commits sin cambios de texto quedaron **2 238 commits** de 115 autores, cada uno clasificado por palabras clave (corrección, funcionalidad, pruebas, refactorización, documentación, mantenimiento), y se contaron los commits de cada uno de los 523 días hábiles.

c) Análisis. *c.1 Llegadas diarias.* $\bar{x} = 4.0899$ y $s^2 = 10.2927$: la varianza es 2.517 veces la media, cuando la Poisson exige que sean iguales (*sobredispersión*).

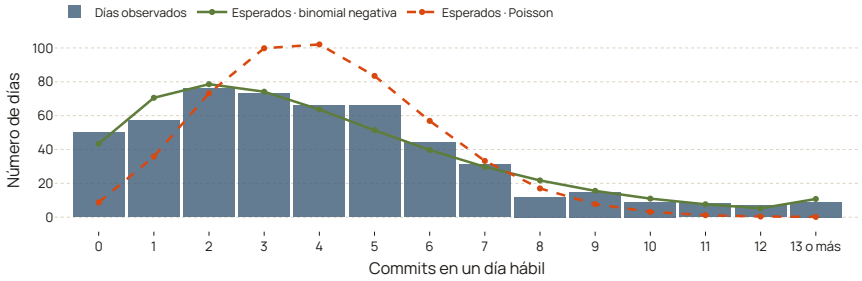


Figura 9. Días hábiles según el número de commits, con lo esperado por cada modelo.

Tabla 9. Prueba χ^2 para las llegadas diarias.

Modelo	Parámetros	EP	v	Crítico	Valor P	P95
Poisson	λ = 4.0899	334.08	8	15.507	< 0.0001	8
Binomial negativa	r = 2.697, p = 0.397	14.09	11	19.675	0.2278	10

La Poisson se rechaza con contundencia ($EP = 334.08$, $v = 8$, $P < 0.0001$): hay 50 días sin commits cuando esperaba 8.8, y muchos más días de alta actividad. La **binomial negativa** —una Poisson cuya tasa cambia de un día a otro— sí se ajusta ($P = 0.2278$). La diferencia es práctica: el percentil 95 con Poisson sería 8 commits/día; con la binomial negativa, 10, y el real fue 10.

c.2 Tamaño de los cambios. Va de 1 a 50 726 líneas, con mediana 87 y media 294. Entre gamma, Weibull, exponencial y lognormal, la **lognormal** tiene el menor AIC ($\hat{\mu} = 4.284$, $\hat{\sigma} = 1.791$ en ln líneas). Con $n = 2\,238$ las pruebas la rechazan (χ^2 equiprobable $P < 0.0001$; KS $D = 0.0466$, $P0.0020$; AD $P0.0020$): hay 264 commits de 6 líneas o menos donde el modelo espera 186.5. Con muestras tan grandes cualquier desviación pequeña es significativa; el modelo describe bien el centro y la cola derecha.

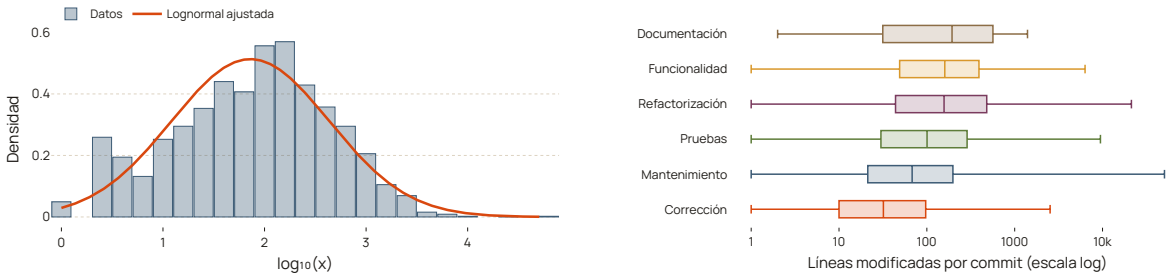


Figura 10. Tamaño de los commits en escala logarítmica con la lognormal ajustada, y tamaño por tipo de cambio.

c.3 Funcionalidades frente a correcciones. Como los tamaños no son normales se usó Mann–Whitney: mediana de 160 líneas en 535 funcionalidades y de 32 en 538 correcciones; $Z = 13.44$, $P < 0.0001$. En el 73.7 % de los pares la funcionalidad es más grande (SE RECHAZA H_0).

c.4 Correlación y regresión. El coeficiente de Pearson entre archivos y líneas modificadas es apenas $r = 0.080$, porque unos pocos commits gigantes dominan el cálculo; el de Spearman (rangos) es $\rho = 0.645$, y en escala log-log $r = 0.611$, con $\log_{10}\widehat{\text{líneas}} = 1.2610 + 0.7713\log_{10}$ archivos ($R^2 = 0.373$): duplicar los archivos multiplica las líneas por 1.71. *c.5* El 24.0 % de los commits son correcciones (IC 95 %: 22.3–25.8 %); la proporción subió de 20.5 % en 2024 a 26.3 % en 2025 ($Z = -3.089$, $P = 0.0020$).

LECTURA

d) Conclusiones y recomendaciones. (1) No asumir Poisson para la llegada de trabajo humano: dimensionar la CI con la binomial negativa (P95 = 10 commits/día). (2) El tamaño de un cambio es aproximadamente lognormal: reportar medianas y percentiles, no promedios (la media, 294 líneas, es más de tres veces la mediana). (3) Las funcionalidades son 5.0 veces más grandes que las correcciones: conviene dividirlas en cambios pequeños para revisarlas mejor. (4) Para relacionar métricas de software, usar Spearman o transformar a logaritmos. (5) El aumento de las correcciones sugiere reforzar las pruebas automatizadas.

4.2 Ingeniería Industrial: ¿el proceso es capaz y está bajo control?

a) Problema. (1) Los anillos de pistón de un motor deben medir 74.000 ± 0.050 mm: ¿el proceso está bajo control, es capaz y cambió durante la vigilancia? (2) Una máquina llena latas de jugo y cada media hora se inspeccionan 50: ¿los defectuosos siguen una binomial y mejoró el proceso tras ajustar la máquina? Se requieren mediciones o conteos agrupados en muestras pequeñas a lo largo del tiempo.

b) Datos. Dos bases reales de Montgomery [4], distribuidas en el paquete `qcc` de R [16]: 40 muestras de 5 diámetros (las 25 primeras, fase I) y 54 muestras de 50 latas (las 30 primeras, fase I; las muestras 15 y 23 tienen causas asignables documentadas y se excluyen).

c) Análisis. Con la fase I, $\bar{\bar{x}} = 74.00118$ y $\bar{R} = 0.02276$, de modo que $LSC_{\bar{x}} = 74.01431$, $LIC_{\bar{x}} = 73.98804$ y $LSC_R = 0.04811$.

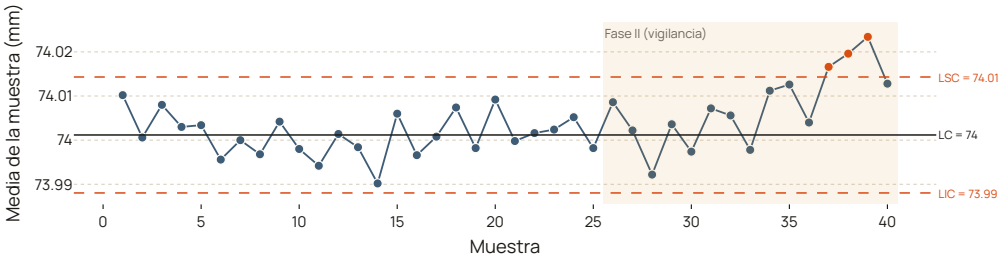


Figura 11. Carta $\bar{X}$ de los anillos de pistón. En rojo, los puntos fuera de control.

Los diámetros de la fase I son normales (χ^2: $P = 0.606$; KS: $P = 0.913$; AD: $P = 0.897$), lo que valida la carta y los índices: $C_p = 1.655$ y $C_{pk} = 1.616$, ambos mayores que 1.33. El proceso es **capaz** (se esperan 0.8 piezas defectuosas por millón) y está centrado (IC 95 % de μ: [73.9994, 74.0030] mm; $t = 1.306$, $P = 0.194$ frente a 74). En la fase II, las muestras 37, 38 y 39 salen sobre el límite: la media se desplazó de 74.0012 a 74.0077 mm, 6.5 micras (IC 95 %: 3.1 a 9.8 micras), lo que la prueba t confirma ($t = -3.827$, $P0.0002$), mientras que la variabilidad no cambió de forma clara ($F = 1.519$, $P = 0.040$).

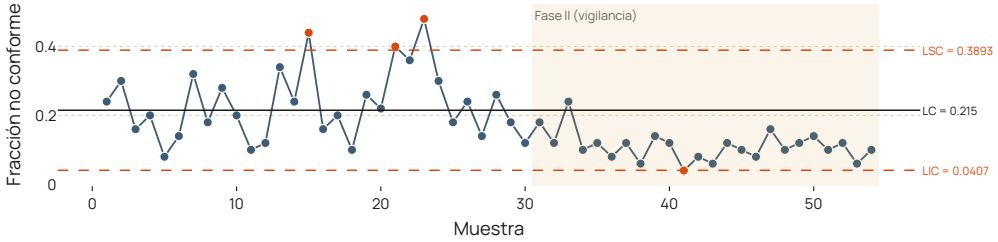


Figura 12. Carta p de las latas de jugo; las muestras 15 y 23 (causas asignables) se excluyen del cálculo.

Con $\bar{p} = 0.2150$, los límites son $LSC = 0.3893$ y $LIC = 0.0407$. El número de latas defectuosas por muestra se ajusta a una Binomial$(50,\ 0.2150)$: $EP = 3.0760$, $v = 4 - 1 - 1 = 2$, crítico 5.9915, $P = 0.2148$ (NO SE RECHAZA H_0). Tras ajustar la máquina la fracción bajó a 0.1108; la prueba de dos proporciones da $Z = 7.101$, $P < 0.0001$: una mejora real de 7.6 a 13.2 puntos porcentuales.

Clase	O_i	P_i	$E_i = nP_i$	$(O_i - E_i)^2/E_i$
0–8	9	0.22338	6.255	1.2049
9 y 10	6	0.25552	7.154	0.1863
11 y 12	4	0.25443	7.124	1.3699
13–50	9	0.26667	7.467	0.3148

LECTURA

d) Conclusiones y recomendaciones. (1) El proceso de anillos es capaz y estuvo bajo control en la fase I. (2) En la fase II la media subió 6.5 micras: aunque todavía no hay piezas fuera de especificación, debe buscarse la causa antes de que el corrimiento crezca. (3) El ajuste de la llenadora redujo los defectuosos de 0.2150 a 0.1108, pero un 11 % sigue siendo alto: se recomienda un análisis de Pareto de las causas y recalcular la carta p. (4) Las cartas dependen de los modelos normal y binomial: las pruebas de ajuste no son un trámite, sino lo que hace válidos sus límites.

Conclusiones

1. **Hornos.** Marca 2 es la marca de mejor desempeño global: la que menos contamina y menos se daña. Su potencia media está entre 2.6959 y 2.7083 kW (centrada en 2.70) y su cumplimiento de emisiones es consistente con la afirmación del fabricante (80 %). Marca 3 es la más uniforme en potencia: su varianza es significativamente menor que la de Marca 4.
2. **Equipos A y B.** Las pruebas t y Z dan el mismo estadístico y valores P casi iguales con $n = 60$; la t es ligeramente más conservadora. Con datos gamma, Mann–Whitney es la prueba adecuada. El estudio de Monte Carlo mostró que con 60 datos la potencia para detectar 5 ms de diferencia es de solo 10.2 %.
3. **Las tres pruebas de ajuste se complementan.** χ^2 es la única para variables discretas; KS y AD aprovechan cada dato y, con los valores P corregidos por simulación, son las más potentes. AD destaca en las colas, que es donde suelen estar los problemas de ingeniería.
4. **Datos reales.** La llegada de trabajo a un repositorio no es Poisson sino binomial negativa, y el tamaño de los cambios es aproximadamente lognormal; el proceso de anillos es capaz pero se desplazó en la vigilancia, y el ajuste de la llenadora mejoró la calidad de forma significativa.
5. **Valor de la herramienta.** La aplicación en Python replica exactamente el ejemplo de la guía ($EP = 6.38393$, $P = 0.4957$), permite repetir cada análisis con otros datos y hace explícitos los supuestos que el Excel no muestra.

Referencias

[1] H. Fernández C., "Pruebas de bondad de ajuste", guía del curso Estadística para Ingeniería, Facultad de Ingenierías, Universidad de Medellín, 2026.

[2] R. E. Walpole, R. H. Myers, S. L. Myers y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9.ª ed. México: Pearson, 2012.

[3] D. C. Montgomery y G. C. Runger, *Applied Statistics and Probability for Engineers*, 7.ª ed. Hoboken, NJ: Wiley, 2018.

[4] D. C. Montgomery, *Introduction to Statistical Quality Control*, 8.ª ed. Hoboken, NJ: Wiley, 2019.

[5] A. N. Kolmogorov, "Sulla determinazione empirica di una legge di distribuzione", *Giornale dell'Istituto Italiano degli Attuari*, vol. 4, pp. 83–91, 1933.

[6] N. Smirnov, "Table for estimating the goodness of fit of empirical distributions", *Ann. Math. Statist.*, vol. 19, no. 2, pp. 279–281, 1948.

[7] T. W. Anderson y D. A. Darling, "Asymptotic theory of certain 'goodness of fit' criteria based on stochastic processes", *Ann. Math. Statist.*, vol. 23, no. 2, pp. 193–212, 1952.

[8] T. W. Anderson y D. A. Darling, "A test of goodness of fit", *J. Amer. Statist. Assoc.*, vol. 49, no. 268, pp. 765–769, 1954.

[9] M. A. Stephens, "EDF statistics for goodness of fit and some comparisons", *J. Amer. Statist. Assoc.*, vol. 69, no. 347, pp. 730–737, 1974.

[10] H. W. Lilliefors, "On the Kolmogorov–Smirnov test for normality with mean and variance unknown", *J. Amer. Statist. Assoc.*, vol. 62, no. 318, pp. 399–402, 1967.

[11] N. M. Razali y Y. B. Wah, "Power comparisons of Shapiro–Wilk, Kolmogorov–Smirnov, Lilliefors and Anderson–Darling tests", *J. Stat. Model. Anal.*, vol. 2, no. 1, pp. 21–33, 2011.

[12] H. B. Mann y D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other", *Ann. Math. Statist.*, vol. 18, no. 1, pp. 50–60, 1947.

[13] F. Wilcoxon, "Individual comparisons by ranking methods", *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[14] N. Forsgren, J. Humble y G. Kim, *Accelerate: The Science of Lean Software and DevOps*. Portland, OR: IT Revolution Press, 2018.

[15] Streamlit Inc., "streamlit/streamlit", repositorio de GitHub. [En línea]. Disponible en: https://github.com/streamlit/streamlit. Consultado: 30 oct. 2026.

[16] L. Scrucca, "qcc: an R package for quality control charting and statistical process control", *R News*, vol. 4, no. 1, pp. 11–17, 2004.

[17] P. Virtanen *et al.*, "SciPy 1.0: fundamental algorithms for scientific computing in Python", *Nature Methods*, vol. 17, pp. 261–272, 2020.

A La herramienta en Python

La aplicación se ejecuta con `python -m streamlit run app.py` y se organiza en un índice lateral de ocho páginas: portada con el mapa de temas del curso, los tres puntos del proyecto, el laboratorio de datos propios, la teoría de las pruebas de ajuste y el taller de la guía. El nivel de significancia, la confianza, la semilla y el número de repeticiones de Monte Carlo se cambian en la barra lateral y todo se recalcula.

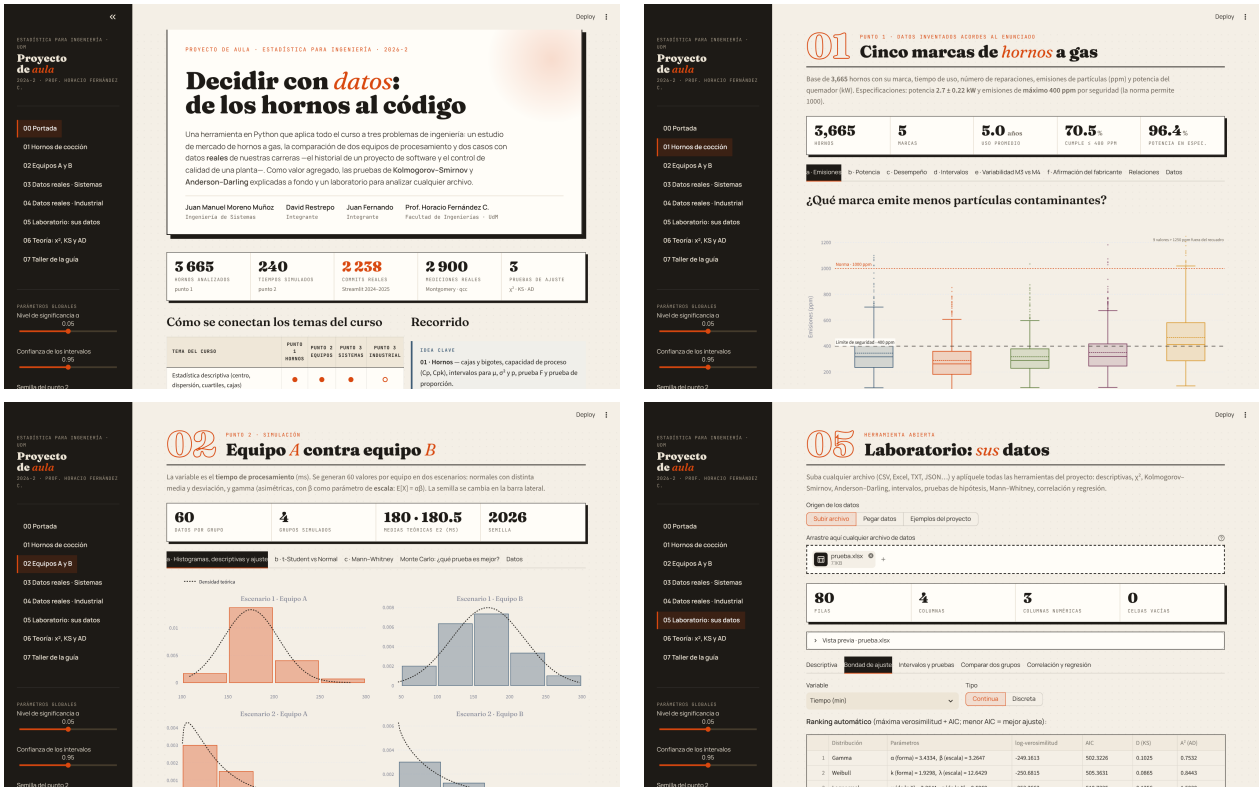


Figura 13. Portada, punto 1, punto 2 y laboratorio con un archivo de Excel cargado.

Laboratorio. Acepta CSV, TXT, TSV (separados por coma, punto y coma, tabulador o espacios, con decimales de punto o de coma), Excel (`.xlsx`, `.xls`, `.ods`), JSON y Parquet; también se pueden pegar datos copiados de Excel. Para la columna elegida ofrece medidas descriptivas, un ranking automático de distribuciones por AIC, las tres pruebas de ajuste (o χ^2 para Poisson, binomial y binomial negativa si la variable es discreta), intervalos y pruebas sobre la media y la proporción, comparación de dos grupos (F, Levene, t, Z, Mann–Whitney) y correlación y regresión.

Estructura del repositorio. `app.py` (interfaz); `src/` con el motor estadístico (`bondad.py`, `inferencia.py`, `descriptiva.py`, `montecarlo.py`, `hornos.py`, `aplicaciones.py`, `taller.py`) separado de las páginas (`src/paginas/`); `scripts/` para regenerar los datos y todos los números y figuras del informe; `data/` con las bases; `excel/` y `r/` con los cálculos equivalentes. Las pruebas se apoyan en NumPy, SciPy [17], pandas y Plotly.

B Taller de la guía resuelto

El motor de la aplicación se validó con el ejemplo de la guía: reproduce $EP = 6.38393$, $v = 7$ y $P = 0.4957$ con las mismas probabilidades redondeadas a cinco decimales. La tabla 10 resume el ejemplo y los seis ejercicios. *Nota:* la última línea del ejemplo en la guía dice que H_0 "debe ser rechazada"; como $P = 0.4957 > 0.05$, la conclusión correcta es que *no* se rechaza, como indica el párrafo anterior de la misma guía.

Tabla 10. Ejemplo y ejercicios de la guía de bondad de ajuste.

Problema	Modelo	k	p	v	EP	Crítico	Valor P	α	Decisión
Ejemplo ASTON	Poisson(3.048)	9	1	7	6.3839	14.067	0.4957	0.05	No rechaza
Ejercicio 1	Normal(μ = 2.5, σ = 0.4)	5	0	4	9.6909	9.488	0.0460	0.05	Rechaza
Ejercicio 2	Normal($\bar{x}$ = 0.173, s = 0.066)	5	2	2	1.6072	5.991	0.4477	0.05	No rechaza
Ejercicio 3	Poisson(λ = 2.1)	6	1	4	4.1281	13.277	0.3889	0.01	No rechaza
Ejercicio 4	Poisson(λ = 190/100 = 1.9)	5	1	3	11.5318	7.815	0.0092	0.05	Rechaza
Ejercicio 5	Poisson(λ = 0.5)	3	0	2	4.6097	5.991	0.0998	0.05	No rechaza
Ejercicio 6	Binomial(n = 3, $\hat{p}$ = 0.9000)	3	1	1	13.5954	3.841	0.0002	0.05	Rechaza

- **Ej. 1.** Se rechaza la Normal(2.5, 0.4) al 5 % por poco: en la clase $x > 2.95$ hay 22 baterías y se esperaban 13; las baterías duran más de lo propuesto. Con $\alpha = 0.01$ no se rechazaría.
- **Ej. 2.** No se rechaza la normalidad de la rentabilidad diaria ($p = 2$ parámetros estimados).
- **Ej. 3.** No se rechaza la Poisson para las averías semanales con $\alpha = 0.01$.
- **Ej. 4.** Se rechaza la Poisson: las llegadas son más regulares de lo que predice (varianza menor que la media), con exceso de minutos con 2 y 3 vehículos.
- **Ej. 5.** No se rechaza la Poisson(0.5) para los defectos del componente AH233.
- **Ej. 6.** Se rechaza la binomial: hay demasiados días con 0 o 1 acciones vendidas; las tres acciones de un mismo día no son independientes porque todas dependen del mercado de ese día.

C Reproducibilidad: Python, Excel y R

Tabla 11. Equivalencia de los cálculos principales.

Cálculo	Excel	R
$t_{\alpha/2,n-1}$, $\chi^2_{\alpha,\nu}$, $z_{\alpha/2}$	`T.INV.2T`, `CHISQ.INV.RT`, `NORM.S.INV`	`qt`, `qchisq`, `qnorm`
Probabilidades P_i	`NORM.DIST`, `POISSON.DIST`, `BINOM.DIST`, `GAMMA.DIST`	`pnorm`, `dpois`, `dbinom`, `pgamma`
Valor P de χ^2	`CHISQ.DIST.RT(EP; v)`	`pchisq(EP, v, lower.tail = FALSE)`
Prueba F y t	`F.TEST`, `T.TEST`	`var.test`, `t.test`
KS y AD	estadísticos con fórmulas por fila	`ks.test`, `nortest::ad.test`, `nortest::lillie.test`
Mann–Whitney	rangos con `RANK.AVG`	`wilcox.test`

Los datos simulados se generan en Python con la semilla 2026 y se guardan en `data/`; Excel y R leen esos mismos archivos, de modo que los tres entornos trabajan sobre los mismos números. Para regenerar todo:

```
python scripts/generar_datos.py · python scripts/generar_informe.py · python scripts/generar_excel.py
```